

TP Natural Language Toolkit (NLTK)

Introduction

Le traitement automatique du langage naturel (NLP: Natural Language Processing) provient d'un processus automatique ou semi-automatique du langage humain. Le NLP fut développé autour de la recherche linguistique et des sciences cognitives, la psychologie, la biologie et les mathématiques. Dans le domaine particulier de l'informatique, la NLP est rattachée aux techniques de compilation, au théorie formelle du langage, à l'interaction homme-machine.

A travers ce tutoriel, nous allons découvrir de cette plateforme NLP portant le nom de Natural Language Toolkit (NLTK).

C'est quoi NLTK ?

Natural Language Toolkit (NLTK) est une boîte-à-outil permettant la création de programmes pour l'analyse de texte. Cet ensemble a été créé à l'origine par Steven Bird et Edward Loper, en relation avec des cours de linguistique informatique à l'Université de Pennsylvanie en 2001. Il existe un manuel d'apprentissage pour NLTK titré Natural Language Processing with Python (<https://www.nltk.org/book/>).

Pour résumer, NLTK est une bibliothèque Python dédiée au traitement naturel du langage ou Natural Language Processing.

Installation de NLTK

Commençons par installer la librairie NLTK pour démarrer nos prochaines expérimentations en analyse du langage naturel.

Son installation est assez simple¹. Sur un terminal, la commande suivante est alors exécutée :

```
Entrée [ ]:pip install nltk
```

Pour vérifier si NLTK est correctement installé, nous allons procéder comme suit :

```
Entrée [ ]:import nltk
          nltk.__version__
```

```
Out[2]:
'3.6.5'
```

Si on obtient la version de NLTK, alors : vous avez bien installé avec succès la librairie.

A noter que vous pourriez avoir une version différente de NLTK, selon le moment où vous installez la bibliothèque, mais ça ne devrait pas causer de problèmes.

Travailler avec NLTK

La première chose à faire pour utiliser NLTK est de télécharger ce qui se nomme le **NLTK corpora**. Je vais télécharger tout le Corpus de taille 10,9 Go.

Petit préambule : vous devez vous demander ce qu'est un corpus (la déclinaison au singulier de corpora). Un corpus est défini de cette façon :

Corpus, pluriel : corpora ; Une collection de données linguistiques, parfois une compilation de textes écrits, ou de transcriptions d'enregistrement de discours. La raison principale d'un corpus est de vérifier une hypothèse sur le langage - par exemple : déterminer comment

¹ <https://www.nltk.org/install.html>


l'utilisation d'un son particulier, d'un mot ou d'une construction syntaxique varie. Les corpus linguistiques agissent avec les lois et les pratiques d'utilisation de corpora dans l'étude du langage. Un corpus informatique contient un ensemble vaste de textes traduisibles en langage-machine.

(Cristal, David. 1992. *An Encyclopedic Dictionary of Language and Languages*. Oxford : Blackwell.)


Ainsi, un corpus est tout simplement un énorme ensemble de textes.

Entrée []:import nltk
nltk.download()
showing info https://raw.githubusercontent.com/nltk/nltk_data/gh-pages/index.xml

Dans ce cas précis, une interface graphique s'affiche :




Vous permettant de définir la destination des fichiers et de sélectionner ce dont vous avez besoin, selon cette illustration :




Les destinations sont les suivantes :

- 'C:\Users\user1\nltk_data'
- 'D:\ProgramData\Anaconda3\nltk_data'

- 'D:\ProgramData\Anaconda3\share\nltk_data'
- 'D:\ProgramData\Anaconda3\lib\nltk_data'
- 'C:\Users\user1\AppData\Roaming\nltk_data'
- 'C:\nltk_data'
- 'D:\nltk_data'
- 'E:\nltk_data'



Si vous connaissais déjà quel corpus vous utiliserez, inutile de télécharger cet ensemble. Exemple dans l'onglet Corpora choisir **city_database** :



Corpora "Stop Words"

Parfois, nous avons besoin de "raboter" des éléments inutiles afin que les données soient davantage traduisibles pour l'ordinateur. En NLP, de telles données (des mots, words) sont qualifiées par stop words. Par conséquent, ces mots n'ont aucune signification pour nous, et nous souhaiterions les retirer.

NLTK Downloader			
File View Sort Help			
Collections Corpora Models All Packages			
Identifier	Name	Size	Status
product_reviews_1	Product Reviews (5 Products)	138.0 KB	not installed
product_reviews_2	Product Reviews (9 Products)	166.7 KB	not installed
proppbank	Proposition Bank Corpus 1.0	5.1 MB	not installed
pros_cons	Pros and Cons	728.8 KB	not installed
ptb	Penn Treebank	6.1 KB	not installed
qc	Experimental Data for Question Classification	122.5 KB	not installed
readers	The Reuters-21578 benchmark corpus, AptelMod version	6.1 MB	not installed
rte	PASCAL RTE Challenges 1, 2, and 3	377.2 KB	not installed
semcor	SemCor 3.0	4.2 MB	not installed
senseval	SENSEVAL 2 Corpus: Sense Tagged Text	2.1 MB	not installed
sentence_polarity	Sentence Polarity Dataset v1.0	478.9 KB	not installed
sentwordnet	SentiWordNet	4.5 MB	not installed
shakespeare	Shakespeare XML Corpus Sample	464.3 KB	not installed
sinica_treebank	Sinica Treebank Corpus Sample	885.5 KB	not installed
smulttron	SMULTRON Corpus Sample	162.3 KB	not installed
state_union	C-Span State of the Union Address Corpus	799.9 KB	not installed
stopwords	Stopwords Corpus	31.5 KB	installed
subjectivity	Subjectivity Dataset v1.0	509.4 KB	not installed
swadesh	Swadesh Wordlists	22.3 KB	not installed
switchboard	Switchboard Corpus Sample	772.6 KB	not installed
timt	TIMIT Corpus Sample	21.2 MB	not installed
toolbox	Toolbox Sample Files	244.7 KB	not installed
treebank	Penn Treebank Sample	1.7 MB	not installed
twitter_samples	Twitter Samples	15.3 MB	not installed
udhr	Universal Declaration of Human Rights Corpus	1.1 MB	not installed
udhr2	Universal Declaration of Human Rights Corpus (Unicode Version)	1.6 MB	not installed
unicode_samples	Unicode Samples	1.2 KB	not installed
universal_treebanks_v20	Universal Treebanks Version 2.0	24.7 MB	not installed
verbnet	VerbNet Lexicon, Version 2.1	316.1 KB	not installed
verbnet3	VerbNet Lexicon, Version 3.3	470.7 KB	not installed
webtext	Web Text Corpus	631.1 KB	not installed
wordnet	WordNet	10.3 MB	not installed
wordnet2021	Open English Wordnet 2021	10.8 MB	not installed
wordnet31	Wordnet 3.1	10.5 MB	not installed
wordnet_ic	WordNet-InfoContent	11.5 MB	not installed
words	Word Lists	740.0 KB	not installed
ycce	York-Toronto-Helsinki Parsed Corpus of Old English Prose	0.5 KB	not installed

Download
Refresh

Server Index: https://raw.githubusercontent.com/nltk/nltk_data/gh-pages/index.xml
Download Directory: D:\Programations\NLP\nltk_data

La librairie NLTK contient quelques mots "d'arrêt" pour commencer ce traitement. Pour les connaître, écrivons ce petit script :

```
Entrée [ ]:from nltk.corpus import stopwords
          print(set(stopwords.words('English')))
```

Et dans ce cas, vous obtiendrez le résultat suivant

```
{'ain', 'aren', 'he', 'for', 'itself', 'you', 'up', 'the', 'nor', 'whom', '
my', 'be', 'out', 'more', 'some', 'our', 'himself', 'is', 'where', 'were',
'how', "don't", 'doing', 'while', 'same', 'haven', 'didn', 'that', 'o', 'wo
n', "she's", "won't", 'under', 'hadn', 'she', "shan't", 'about', 'at', 'the
m', 't', 'had', 'am', 'who', 'wouldn', 'its', 'through', 'me', "hasn't", 'a
re', 'an', 'myself', 've', 'does', 'only', 'above', "that'll", 'against', '
too', 'own', 'so', 's', "haven't", 'this', 'shan', 'i', "should've", 'their
', 'here', 'll', 'with', 'there', 'have', 'yours', 'just', 'such', "wasn't"
, "it's", 'yourself', 'hasn', 'both', 'and', 'of', 'ours', 'further', "aren
't", 'over', "couldn't", 'or', 'by', 'has', 'themselves', 'below', 'isn', "
mightn't", "wouldn't", 're', 'on', 'don', 'wasn', 'd', "you'll", 'each', 'd
o', 'a', 'down', 'should', 'these', 'being', 'to', 'was', 'those', "shouldn
't", 'm', 'in', 'then', 'having', 'his', "you're", 'which', 'few', 'mightn'
, 'not', 'than', 'mustn', 'will', "weren't", 'any', 'all', "hadn't", 'it',
'again', 'why', 'herself', 'most', 'her', "you've", 'they', 'after', 'into'
, 'what', 'off', 'theirs', 'weren', 'needn', 'y', 'did', 'yourselves', 'ma'
, 'during', 'him', 'ourselves', 'from', 'before', 'no', "doesn't", 'as', "n
eedn't", 'when', 'can', "mustn't", 'couldn', 'but', 'because', 'been', 'now
', "isn't", 'other', 'we', 'your', 'very', 'shouldn', "you'd", 'if', 'once'
, 'until', 'doesn', 'hers', 'between', "didn't"}
```

Nous avons ainsi listé une collection non-ordonnée d'éléments, connu comme "mots d'arrêt", en langue anglaise, dans ce cas.

Mais comment pourrions-nous éliminer ces mots de notre texte ?

Premierement il faut télécharger le corpora 'punkt' de la bibliothèque nltk

```
import nltk
```

```
nltk.download('punkt')
```

L'exemple suivant montre comment y parvenir :

```
from nltk.corpus import stopwords
from nltk.tokenize import word_tokenize

text = 'In this tutorial, I\'m learning NLTK. It is an interesting
library.'
stop_words = set(stopwords.words('english'))
words = word_tokenize(text)

new_sentence = []

for word in words:
    if word not in stop_words:
        new_sentence.append(word)

print(new_sentence)
text = 'In this tutorial, I\'m learning NLTK. It is an interesting
platform.'
stop_words = set(stopwords.words('english'))
words = word_tokenize(text)

new_sentence = []

for word in words:
    if word not in stop_words:
        new_sentence.append(word)

print(new_sentence)
```